

# 선형회귀 #2

## (Linear Regression)


한국공학대학교  
전자공학부  
채승호 교수

# 단항 선형회귀

## ■ 단항 선형회귀

- ▶ 입력속성이 한 개인 경우의 선형회귀
- ▶ 1개의 입력 속성 & 1개의 출력 속성으로 이루어진 2차원 속성 공간
- ▶ 1차 직선으로 모델링
  - 2개의 매개변수 최적화 문제 :  $\hat{y} = w_0x + w_1$

데이터번호	무게(g)	늘어난길이(cm)
1	5	11.66
2	6	13.10
3	7	13.79
4	8	16.71
5	9	17.74
6	10	18.70



# 다항 선형회귀

## ■ 다항 선형회귀

- ▶ 입력 속성이 1개 이상인 경우의 선형회귀
- ▶ 입력 속성의 증가로 다차원 속성공간 생성
- ▶ 입력 속성이  $M$ 개인 훈련 데이터 집합의 표현

데이터 번호	입력	출력
0	$x_{0,0}, x_{1,0}, \dots, x_{m,0}, \dots, x_{M-1,0}$	$y_0$
1	$x_{0,1}, x_{1,1}, \dots, x_{m,1}, \dots, x_{M-1,1}$	$y_1$
$\vdots$	$\vdots$	$\vdots$
$n$	$x_{0,n}, x_{1,n}, \dots, x_{m,n}, \dots, x_{M-1,n}$	$y_n$
$\vdots$	$\vdots$	$\vdots$
$N - 1$	$x_{0,N-1}, x_{1,N-1}, \dots, x_{m,N-1}, \dots, x_{M-1,N-1}$	$y_{N-1}$

### ▶ 다항 선형모델

- $\hat{y} = w_0x_0 + w_1x_1 + \dots + w_{M-1}x_{M-1} + w_M$
- 학습을 통해  $M + 1$ 개의 최적 매개변수를 구함

# 다항 선형회귀

## ■ Cost Function

- 단일 변수에 대한 평균제곱오차

$$\epsilon_{MSE} = \frac{1}{N} \sum_{n=0}^{N-1} (\hat{y}_n - y_n)^2 = \frac{1}{N} \sum_{n=0}^{N-1} (w_0 \boxed{x_n} + w_1 - y_n)^2$$

단일변수(용수철무게)

- 다항 변수에 대한 평균제곱오차

$$\epsilon_{MSE}(w_0, w_1, \dots, w_M) = \frac{1}{N} \sum_{n=0}^{N-1} (\hat{y}_n - y_n)^2 = \frac{1}{N} \sum_{n=0}^{N-1} (w_0 \boxed{x_{0,n}} + w_1 \boxed{x_{1,n}} + \dots + w_M \boxed{y_n})^2$$

input      input      output  
속도      질량      거리

n: 측정된 데이터 수에 대한 index  
M: 입력 데이터 Type 수 (데이터 차원 수)

# 다항 선형회귀

## ■ 다항 선형회귀 모델의 해석해를 위한 표현

- ▶ 매개변수 벡터  $\mathbf{w} = [w_0 \ w_1 \ \cdots \ w_{M-1} \ w_M]^T$
- ▶ 출력(라벨) 벡터  $\mathbf{y} = [y_0 \ y_1 \ \cdots \ y_{N-1}]^T$
- ▶ 입력 데이터 행렬  $\mathbf{X}$  ( $N \times M$  행렬)
  - $M$ 개의 입력 속성에 대해  $N$ 개의 데이터가 있음
  - 각 행은 개별 데이터를, 각 열은 개별 속성을 나타냄

데이터 번호	입력	출력
0	$x_{0,0}, x_{1,0}, \dots, x_{m,0}, \dots, x_{M-1,0}$	$y_0$
1	$x_{0,1}, x_{1,1}, \dots, x_{m,1}, \dots, x_{M-1,1}$	$y_1$
$\vdots$	$\vdots$	$\vdots$
$n$	$x_{0,n}, x_{1,n}, \dots, x_{m,n}, \dots, x_{M-1,n}$	$y_n$
$\vdots$	$\vdots$	$\vdots$
$N - 1$	$x_{0,N-1}, x_{1,N-1}, \dots, x_{m,N-1}, \dots, x_{M-1,N-1}$	$y_{N-1}$

$$\mathbf{X} = \begin{bmatrix} x_{0,0} & x_{1,0} & \cdots & x_{M-1,0} \\ x_{0,1} & x_{1,1} & \cdots & x_{M-1,1} \\ \vdots & \vdots & & \vdots \\ x_{0,N-1} & x_{1,N-1} & \cdots & x_{M-1,N-1} \end{bmatrix}$$

$x_{M,0}$   
 $x_{M,1}$   
 $\vdots$   
 $x_{M,N-1}$

$\mathbf{x}_0$   
 $\mathbf{x}_1$   
 $\vdots$   
 $\mathbf{x}_{N-1}$

모두 1

# 다항 선형회귀

## ▶ 선형회귀 모델

- 기존 식

$$\hat{y} = w_0x_0 + w_1x_1 + \cdots + w_{M-1}x_{M-1} + w_M$$

- 편의상 수정

$$\hat{y} = w_0x_0 + w_1x_1 + \cdots + w_{M-1}x_{M-1} + w_Mx_M, \quad x_M = 1$$

$$\Rightarrow \hat{y} = [w_0, w_1, \dots, w_{M-1}, w_M] \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_{M-1} \\ x_M \end{bmatrix} = \mathbf{w}^T \mathbf{x}$$

## ▶ 비용함수(평균제곱오차)

$$\epsilon_{MSE} = \frac{1}{N} \sum_{n=0}^{N-1} (\hat{y}_n - y_n)^2 = \frac{1}{N} \sum_{n=0}^{N-1} (\mathbf{w}^T \mathbf{x}_n - y_n)^2$$

$$\hat{y}_n = [w_0, w_1, \dots, w_{M-1}, w_M] \begin{bmatrix} x_{0,n} \\ x_{1,n} \\ \vdots \\ x_{M-1,n} \\ x_{M,n} \end{bmatrix} = \mathbf{w}^T \mathbf{x}_n \quad x_{M,n} = 1$$

다차원 입력데이터에 대한 Cost Function

→ Cost Function이 최소가 되는  $\mathbf{w} = [w_0 \ w_1 \ w_2 \ \cdots \ w_M]$  가 Optimal Solution

# 다항 선형회귀

## ■ 다항 선형회귀 모델의 해석해

- ▶ 비용 함수를 최소화하는  $M + 1$ 개의 매개변수를 구함

$$\frac{\partial}{\partial w_m} \epsilon_{MSE} = 0, \quad m = 0, 1, \dots, M-1, M$$

$$\rightarrow \frac{\partial}{\partial w_m} \epsilon_{MSE} = \frac{2}{N} \sum_{n=0}^{N-1} (\mathbf{w}^T \mathbf{x}_n - y_n) x_{m,n} = 0 \text{ 이 되는 해}$$

- $m = 0$ 일 때,  $\sum_{n=0}^{N-1} (\mathbf{w}^T \mathbf{x}_n - y_n) x_{0,n} = 0$

- $m = 1$ 일 때,  $\sum_{n=0}^{N-1} (\mathbf{w}^T \mathbf{x}_n - y_n) x_{1,n} = 0$

...

- $m = M$ 일 때,  $\sum_{n=0}^{N-1} (\mathbf{w}^T \mathbf{x}_n - y_n) x_{M,n} = 0$

$$\mathbf{x}_n^T = [x_{0,n}, x_{1,n}, \dots, x_{M-1,n}, x_{M,n}]$$

$$\sum_{n=0}^{N-1} (\mathbf{w}^T \mathbf{x}_n - y_n) \mathbf{x}_n^T = [0, 0, \dots, 0, 0]$$

scalar

- ▶ 결과값

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

역행렬이 항상 존재한다는 것을 보장할 수 없음  
즉, 수치적 접근을 통한 최적해를 구하는 것이 일반적

# 다항 선형회귀

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

## ■ 다항 선형회귀 모델의 해석해 (예)

- ▶ 키와 몸무게로 나이를 추정하는 데이터 집합
  - 입력속성: 키( $x_0$ ), 몸무게( $x_1$ ) / 출력라벨: 나이( $y$ )
- ▶ 선형회귀 모델
  - $\hat{y} = w_0 x_0 + w_1 x_1 + w_2 x_2$ ,  $x_2 = 1$
  - 3차원 공간에서의 평면의 방정식 (M=2)
- ▶ 80개의 데이터 (N=80)


n	x0	x1	y	n	x0	x1	y	n	x0	x1	y	n	x0	x1	y
1	152.6	44.7	11.5	21	64.4	5.5	0.3	41	72.2	8.3	0.8	60	119.9	21.2	7.3
2	160.4	39.9	15.8	22	67.5	7.7	0.6	42	124.6	29.4	8.2	61	160.1	55.3	14.9
3	112.2	21.1	6.6	23	70.7	8.6	0.8	43	134.5	27.8	8.3	62	131.9	27.6	8.2
4	159.3	46.4	15.6	24	162.1	49.4	14.8	44	171.3	53.6	18.8	63	103.7	15.5	4.5
5	150.9	46.6	11	25	167.3	55.6	16.2	45	162.1	49.4	14.8	64	131.9	27.6	8.2
6	91.7	13.1	2.8	26	155	35.8	16.9	46	155	35.8	16.9	65	111.1	21	5.5
7	74.8	8	0.8	27	70.7	8.6	0.8	47	76.7	9.7	1.4	66	86.2	11	2
8	111.1	16.1	4.3	28	74.8	8	0.8	48	159.6	71.5	13.6	67	152	48.8	13.7
9	162.9	43.8	12.8	29	130.5	26.5	8.7	49	150.9	46.6	11	68	103.4	14.2	3.5
10	131.3	27.6	9.6	30	91.7	13.1	2.8	50	159.4	42.9	15.9	69	105.9	14.8	3.6
11	105.3	19.2	4.9	31	108.6	23.4	6.6	51	138.2	30.7	8.3	70	162.1	49.4	14.8
12	177.8	61.7	18.4	32	160.1	40.6	17.9	52	86.2	11	2	71	160.4	39.9	15.8
13	101.8	16.8	4.4	33	94.7	15.1	3.3	53	94.7	15.1	3.3	72	103.7	15.5	4.5
14	151.5	49	12	34	95.3	13.2	2.2	54	154.7	48.1	12.9	73	111.1	21	5.5
15	86.2	11	2	35	162.7	46.9	16.3	55	174.7	74.9	18.4	74	119.9	21.2	7.3
16	137.8	23.7	10.2	36	131.6	35.1	9.2	56	131.3	27.6	9.6	75	164.7	55.5	16.3
17	160.1	40.6	17.9	37	154.7	61.4	16.5	57	113.5	15.3	5.7	76	100.2	14.1	3.3
18	119.9	21.2	7.3	38	64.4	5.5	0.3	58	119.9	21.2	7.3	77	170.1	52.1	18.1
19	156.4	65.9	12.8	39	159.6	71.5	13.6	59	102.6	17.1	3.9	78	152	48.8	13.7
20	154.7	48.1	12.9	40	115.6	24.2	6.8	60	103.4	14.2	3.5	79	114.1	18.6	5.2



# 다항 선형회귀

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

- ▶ 80개의 데이터 (N=80)



# 다항 선형회귀

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

- ▶ 80개의 데이터 (N=80, M=2)

- 입력 행렬  $\mathbf{X}$ ,  $80 \times 3$

152.6	44.7	1
160.4	39.9	1
112.2	21.1	1
159.3	46.4	1
150.9	46.6	1
91.7	13.1	1
74.0	0	1

•  
•  
•

100.2	14.1	1
170.1	52.1	1
152	48.8	1
114.1	18.6	1

- 출력 벡터  $\mathbf{y}$ ,  $80 \times 1$

11.5
15.8
6.6
15.6
11
2.8
0.0


•  
•  
•

10.5
3.3
18.1
13.7
5.2

# 다항 선형회귀

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

- ▶ 80개의 데이터 (N=80, M=2)
  - 최적 매개변수
    - $w_0^* = 0.1625, w_1^* = 0.0198, w_2^* = -12.2758$
  - 최적 선형모델
    - $\hat{y} = 0.1625x_0 + 0.0198x_1 - 12.2758$



# 경사하강법(Gradient Descent Method)


## ■ 위치 업데이트 규칙(다음 시점, $t + 1$ )

$$\alpha \in [0,1]$$

$$\triangleright w_0[t + 1] = w_0[t] - \alpha \left. \frac{\partial}{\partial w_0} \epsilon_{MSE}(w_0, w_1, w_2) \right|_{w_0=w_0[t], w_1=w_1[t], w_2=w_2[t]}$$

$$\triangleright w_1[t + 1] = w_1[t] - \alpha \left. \frac{\partial}{\partial w_1} \epsilon_{MSE}(w_0, w_1, w_2) \right|_{w_0=w_0[t], w_1=w_1[t], w_2=w_2[t]}$$

$$\triangleright w_2[t + 1] = w_2[t] - \alpha \left. \frac{\partial}{\partial w_2} \epsilon_{MSE}(w_0, w_1, w_2) \right|_{w_0=w_0[t], w_1=w_1[t], w_2=w_2[t]}$$




$$\triangleright w_0[t + 1] = w_0[t] - \alpha \frac{2}{N} \sum_{n=0}^{N-1} x_{0,n} (w_0[t]x_{0,n} + w_1[t]x_{1,n} + w_2[t] - y_n)$$

$$\triangleright w_1[t + 1] = w_1[t] - \alpha \frac{2}{N} \sum_{n=0}^{N-1} x_{1,n} (w_0[t]x_{0,n} + w_1[t]x_{1,n} + w_2[t] - y_n)$$

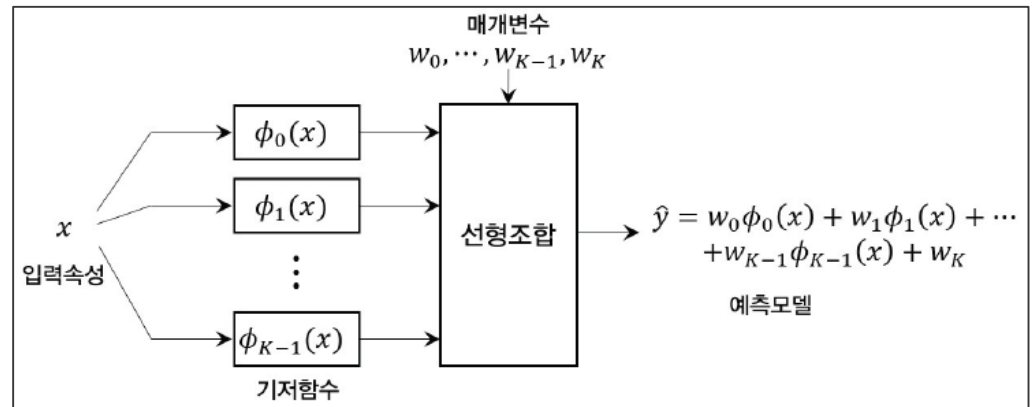
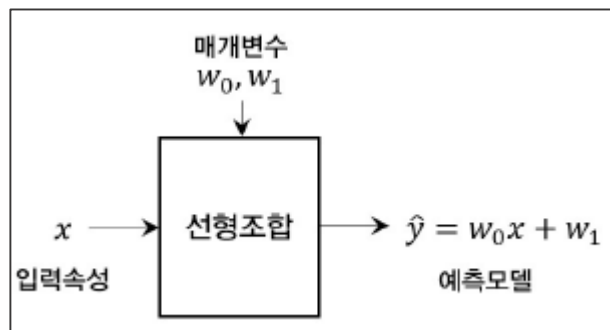
$$\triangleright w_2[t + 1] = w_2[t] - \alpha \frac{2}{N} \sum_{n=0}^{N-1} (w_0[t]x_{0,n} + w_1[t]x_{1,n} + w_2[t] - y_n)$$

Check 필요!!

# 선형기저함수 모델



Non-Linear한 특성을 가지는 함수에 대한 표현을  
선형함수의 조합으로 표현이 가능한가?



Non-Linear 함수들의 조합으로 표현하자!

# 선형기저함수 모델

## ■ 대표적 기저함수 모델


- ▶ Polynomial basis function (다항식 기저함수)

$$\phi_k(x) = x^k$$

- ▶ Gaussian basis function (가우시안 기저함수)

$$\phi_k(x) = e^{-\frac{1}{2}\left(\frac{x-\mu_k}{\sigma}\right)^2}$$

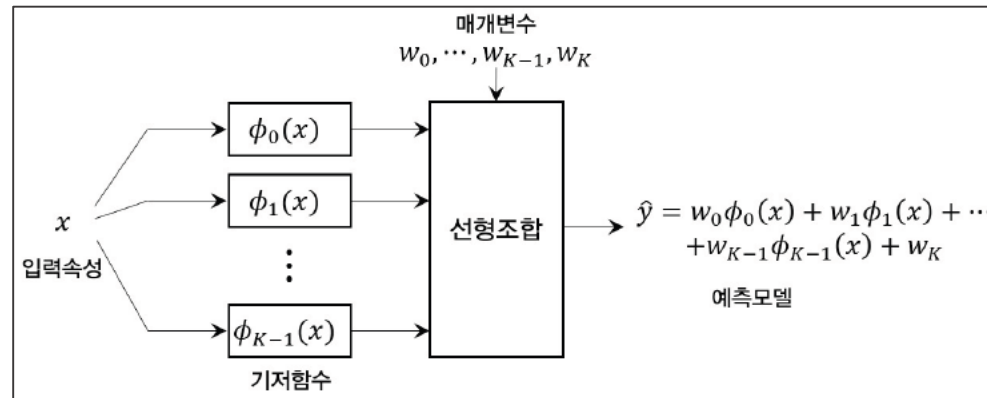
가우시안 함수들의 조합으로  
데이터의 특성 함수를 표현



# 선형기저함수 모델

## ■ 선형기저함수 모델의 해석해

- ▶ 입력이  $K$ 개인 선형회귀 모델과 동일한 방법 사용 가능



- ▶ 예측 출력: 기저함수들의 선형 조합
  - $\phi_K = 1$ : 행렬 표현의 편의를 위해 추가한 변수

$$\hat{y} = [w_0, w_1, \dots, w_{K-1}, w_K] \begin{bmatrix} \phi_0(x) \\ \phi_1(x) \\ \vdots \\ \phi_{K-1}(x) \\ \phi_K(x) \end{bmatrix} = \mathbf{w}^T \boldsymbol{\phi}(x) \quad \mathbf{w} = \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_{K-1} \\ w_K \end{bmatrix} \quad \boldsymbol{\phi}(x) = \begin{bmatrix} \phi_0(x) \\ \phi_1(x) \\ \vdots \\ \phi_{K-1}(x) \\ \phi_K(x) \end{bmatrix}$$

# 선형기저함수 모델

## ■ 선형기저함수 모델의 해석해

- ▶ 비용함수: 평균제곱오차

$$\epsilon_{MSE} = \frac{1}{N} \sum_{n=0}^{N-1} (\hat{y}_n - y_n)^2 = \frac{1}{N} \sum_{n=0}^{N-1} (\boldsymbol{\phi}(x_n) - y_n)^2 \quad \boldsymbol{\phi}(x_n) = \begin{bmatrix} \phi_0(x_n) \\ \phi_1(x_n) \\ \vdots \\ \phi_{K-1}(x_n) \\ \phi_K(x_n) \end{bmatrix}$$

- ▶  $N$ 개 훈련 데이터 입력에 대한 행렬

- (데이터 개수가  $N$ 개임, 각 개수마다 기저는  $K$ 개, 마지막 열은 모두 1 값임)

$$\Phi = \begin{bmatrix} \phi_0(x_0) & \phi_1(x_0) & \cdots & \phi_{K-1}(x_0) & \phi_K(x_0) \\ \phi_0(x_1) & \phi_1(x_1) & \cdots & \phi_{K-1}(x_1) & \phi_K(x_1) \\ \vdots & \vdots & & \vdots & \vdots \\ \phi_0(x_{N-1}) & \phi_1(x_{N-1}) & \cdots & \phi_{K-1}(x_{N-1}) & \phi_K(x_{N-1}) \end{bmatrix}$$

- ▶  $N$ 개 훈련 데이터 출력에 대한 벡터

$$\mathbf{y} = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_{N-1} \end{bmatrix}$$



# 선형기저함수 모델

- 선형기저함수 모델의 해석해

- ▶ 최적 매개변수

$$\mathbf{w} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{y}$$

- ▶ (cf.) 선형회귀 모델의 해석해

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

# 선형기저함수 모델

## ■ 기저함수 개수 $K$ 와 각 기저함수 파라미터 설정


- ▶  $k$ 번째 가우스 함수의 평균

$$\mu_k = x_{\min} + \frac{x_{\max} - x_{\min}}{K - 1} k, \quad k = 0, 1, \dots, K - 1$$

- ▶ 모든 가우스 함수의 분산

$$\sigma = \frac{x_{\max} - x_{\min}}{K - 1}$$

- ▶ (예)



기저함수	매개변수	
	$\mu_k$	$\sigma$
$\phi_0(x)$	5	5
$\phi_1(x)$	10	
$\phi_2(x)$	15	


# 선형기저함수 모델

## ■ 선형기저함수 회귀의 예

- ▶ 최적 매개변수 및 회귀 모델,  $K = 3$

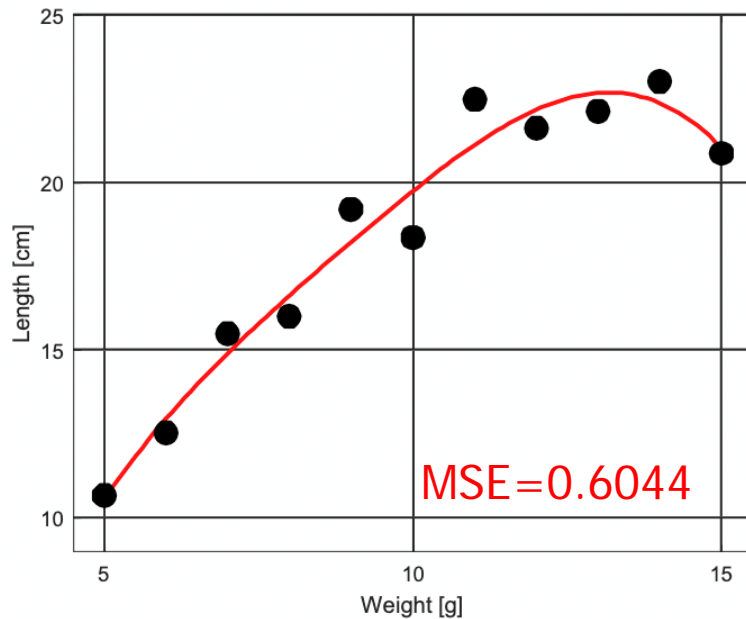
$$\mathbf{w} = \begin{bmatrix} 27.02 \\ 3.46 \\ 39.08 \\ -23.82 \end{bmatrix}$$

$$\hat{y} = 27.02e^{-\frac{1}{2}\left(\frac{x-5}{5}\right)^2} + 3.46e^{-\frac{1}{2}\left(\frac{x-10}{5}\right)^2} + 39.08e^{-\frac{1}{2}\left(\frac{x-15}{5}\right)^2} - 23.82$$




# 선형기저함수 모델

## ■ K값에 따른 성능 비교



K=3



K=8

MSE가 작다고 무조건 좋은 것일까?

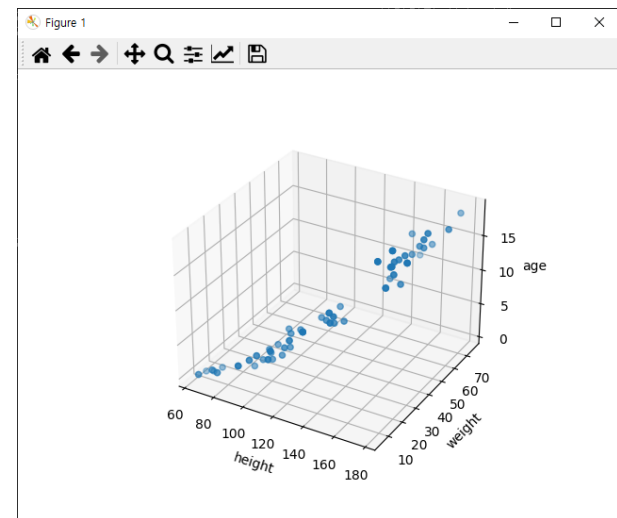
# 실습

## ■ 실습데이터 (파일명: multiple\_linear\_regression\_data.csv)

- ▶ 데이터는 학생들의 키(cm)와 몸무게(kg)를 측정하고 나이를 표시한 것
- ▶ 파일에서 첫번째 열은 키(cm), 두번째 열은 몸무게(kg), 세번째 열은 나이를 의미

## ■ 실습 #1

- ▶ 제공된 데이터 파일을 불러들여 x축은 키(cm), y축은 몸무게(kg), z축은 나이를 나타내는 3차원 공간에 각 데이터의 위치를 점으로 표시하시오.
- ▶ 결과물: 코드, 매개변수
- ▶ Hint) scatter 함수 사용



# 실습

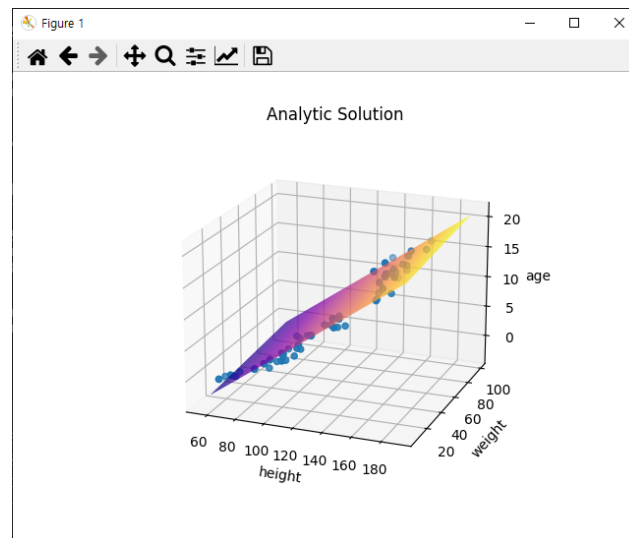
## ■ 실습 #2

- ▶ 해석해로 구한 선형모델과 데이터를 한 그래프에 표시하라.
- ▶ 필수요소: x축, y축, z축 이름, grid, legend
- ▶ 결과물: 그래프
- ▶ Hint) pseudo inverse matrix → `numpy.linalg.pinv()`

평면 생성: `linspace()`로 height, weight 데이터 임의 생성 → `meshgrid()` 사용

3D plot:

```
ax = fig.add_subplot(projection='3d'), ax.plot_surface()
```



# 실습

## ■ 실습 #3

- ▶ 해석해로 구한 선형모델의 평균제곱오차를 구하라.

$$\epsilon_{MSE} = \frac{1}{N} \sum_{n=0}^{N-1} (\hat{y}_n - y_n)^2 = \frac{1}{N} \sum_{n=0}^{N-1} (\mathbf{w}^T \mathbf{x}_n - y_n)^2$$

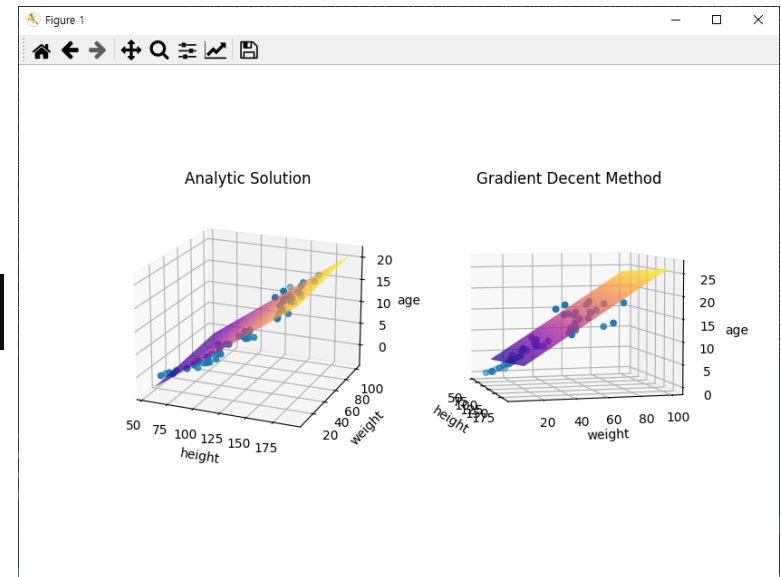
- ▶ 결과물: 코드, 평균제곱오차

# 실습

## ■ 실습 #4

- ▶ 경사하강법 프로그램을 이용해 최적 매개변수를 구하라.
  - 단, 경사하강법 외부 함수 사용 금지.
  - 단, 학습률, 초기값, 반복 회수는 임의로 정하여 사용하라.
- ▶ 결과물: 코드
- ▶ 결과물: 학습률, 초기값, 반복 횟수, 최종 평균제곱오차, 최적 매개변수

```
epoch: 99700 =====> W: [ 0.01793957 0.22764151 -0.12103336 ], gradient: [-0.00340941 0.00488573 0.28744971 ], mse: 5.4463940361853763  
epoch: 99800 =====> W: [ 0.01794298 0.22763662 -0.1213208 ], gradient: [-0.00340933 0.00488561 0.2874427 ], mse: 5.44676389653737  
epoch: 99900 =====> W: [ 0.01794639 0.22763174 -0.12160824 ], gradient: [-0.00340925 0.00488549 0.28743569 ], mse: 5.446599439408866
```





# 실습

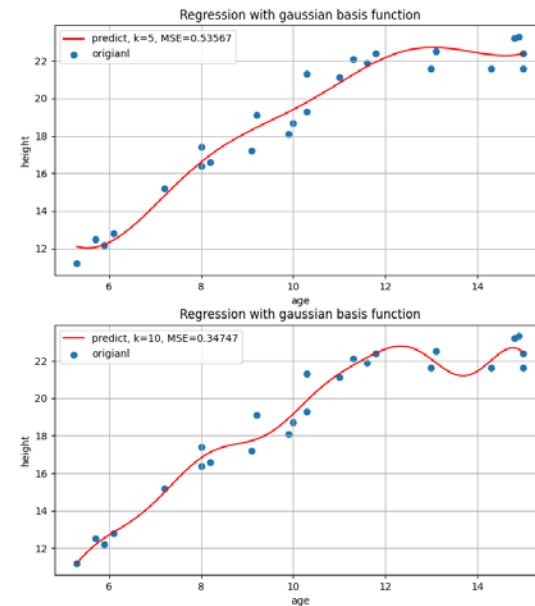
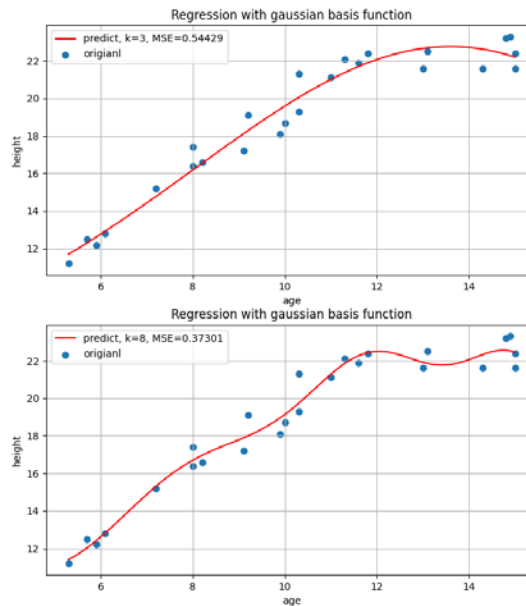
- 실습데이터 (파일명: lin\_regression\_data01.csv → 지난주 data)
  - ▶ 데이터는 유아들의 나이(개월)와 키(cm)를 측정한 것
  - ▶ 파일 형식은 쉼표로 구분된 데이터 파일
  - ▶ 파일에서 첫번째 열은 나이(개월), 두번째 열은 키(cm)를 의미
- 실습 #5
  - ▶ 주어진 데이터에 대해 K개의 가우스 함수를 이용한 선형 기저함수 회귀모델의 최적 매개변수(해석해)를 자동 계산하는 프로그램을 작성하고, K가 3, 5, 8 일 때의 매개변수를 구하라.
  - ▶ 결과물: 코드, 매개변수

$$\mathbf{w} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{y}$$

# 실습

## ■ 실습 #6

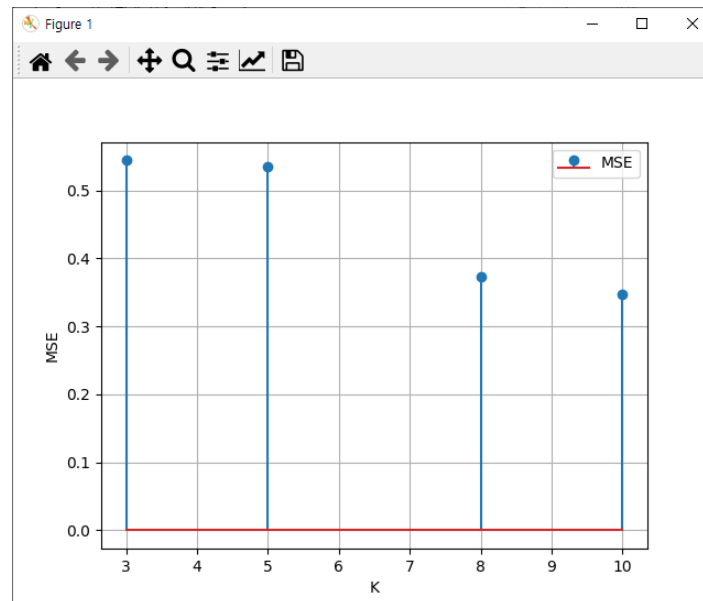
- ▶  $K = 3, 5, 8, 10$ 일 때, 훈련 데이터와 선형 기저함수 회귀 모델을 그래프에 표시하라.
- ▶ 필수요소: x축, y축 이름, grid, legend
- ▶ 결과물: 그래프



# 실습

## ■ 실습 #7

- ▶ 실습 #6에서 각  $K$ 개에 대한 평균제곱오차를 구하고  $x$ 축은  $K$ 값,  $y$ 축은 평균제곱오차를 나타내는 2차원 그래프를 구하라.
- ▶ 필수요소:  $x$ 축,  $y$ 축 이름, grid, legend
- ▶ 결과물: 코드, 그래프



# 보고서 작성

- 각 주차에 해당하는 실습과제에 대해 하나의 보고서로 작성
  - ▶ 보고서 작성 형식은 hwp, word
  - ▶ 첫 페이지(표지)에 0주차, 실습과제 #0, 이름, 학번, 제출 날짜 기입
  - ▶ 각 결과에 대한 해석은 간단 명료하게 서술
- 실행 Code는 보고서에 복사 붙여넣기 하여 넣기
  - ▶ Code를 해석할 수 있는 주석 처리 필수
- 결과는 해당 화면을 캡처하여 보고서에 포함
- 즉시 실행 가능한 .py 파일을 함께 업로드
  - ▶ (Run만 눌러도 오류없이 돌아가는 코드)
  - ▶ 파일명은 본인영문이니셜\_학번.py로 할것

보고서 + .py파일 => 압축하여 학번\_이름.zip으로 e-class에  
제출